실전 1 보고서 2부 ⑦ Holdout 오류 분석

> - **과제**: 금융사 사내 문서에서 개인정보 7종을 찾는 탐지기를 규칙 기반·토큰 분류·LLM 세 방식으로 비교하고, 운영에 쓸 탐지기를 근거 있게 고른다.
> - **데이터**: 제공 `pii_synth_finance` dev 100건(정답 548개) · test 200건(정답 1,165개) / 추가 시험 데이터: 엣지 케이스 64건(정답 116개), 일상 문서 1,983건(정답 3,375개) / **멘토 holdout 187건(정답 912개)**
> - **채점**: 멘토 제공 `run_compare.py` (strict·partial 정밀도/재현율/F1, mask_rec, 라벨별·어려운 사례 재현율, 일관성)
> - **작성**: 2026-10-26 · 저장소 `hosung` 브랜치 `실전프로젝트1/` · 작업 기록 전체는 `worklog.md` (23장)

보고서 구성: 0 요약 및 결론 · **1부** ① 데이터 관찰 리포트 · ② 방식별 비교표 · ③ 오류 유형 분석 · ④ 탐지기 선정 근거 · **2부** ⑤ Holdout 데이터 관찰 · ⑥ Holdout 성능 · ⑦ Holdout 오류 분석 · ⑧ Holdout 개선 내역 · 부록 개선 과정과 데이터 사용 기록 (`report/` 폴더)

개선 전(v7) 결과 기준. 오류 목록: `results/holdout_before/errors_rules+atonlee.csv` (구성 요소: `errors_rules.csv`, `errors_atonlee.csv`). 각 오류가 규칙·토큰 중 어디서 왔는지는 두 탐지기의 개별 예측과 겹치는지로 판단했다.

7-1. 오류 건수

방식	미탐	오탐	경계 오류	라벨 오류
규칙 + 토큰 (최종)	**3**	**65**	14	3
규칙 단독	72	47	8	2
토큰 단독	15	23	28	3

→ 최종 탐지기는 정답 912개 중 **3개만 놓쳤다**. 규칙이 놓친 72개(외자·이름만·새 문서 유형의 이름)를 토큰이 메웠다. 대신 오탐 65건이 정밀도(0.912)를 끌어내렸다.

7-2. 미탐 (3건) — 새로 드러난 이름 형태

사례 (【 】 = 정답)	원인
대상 고객: 【전 찬】	**띄어 쓴 외자**. 필드 규칙이 첫 단어 `전` (한 글자)을 이름이 아니라고 보고 버림. 토큰도 놓침
수취인: 【신설】 (현지 연락…)	외자 이름이 일반 단어(`신설`)와 같음 + 필드 목록에 `수취인` 이 없음
【린】 님이 유학 중인…	**한 글자 이름** (holdout 전체에 1건). 성이 없고 일반 글자와 구분할 단서가 없음

7-3. 경계 오류 (14건)

사례	출처	원인
`【(05299) 서울특별시 강남구 한빛로 9, 2층】` → 우편번호 빠짐 (5건)	규칙·토큰 모두	**주소 앞 우편번호 (5자리)** — dev·test에 없던 표기. 정답은 우편번호까지 주소로 봄
인사팀 【시우】 드림 → `시우 드림` (5건)	토큰	서명 `드림` 을 이름에 포함
심사역 【안윤】이 조건 안내 → `안윤이` (4건: 안윤·오가은·김찬·정별)	규칙·토큰	주격 조사 `이` 를 이름에 포함. 외자 이름이라 `안윤이` 가 3글자 이름처럼 보임

7-4. 라벨 오류 (3건)

사례	출처	원인
`출금 계좌: 누리은행【056-75-340175-9】` → 전화번호로	토큰	계좌 규칙이 마지막 묶음 1자리(3-2-6-**1**)를 지원하지 않아 규칙이 못 잡고, 토큰이 전화로 분류
`반송 주소: 【충청남도 아산시 배방읍 252-4】` → `배방읍` 만 이름으로 (2건)	규칙	**`읍` 바로 뒤에 `번지`**가 오는 지번 주소(리 없음)를 주소 규칙이 지원하지 않음 → 주소를 놓친 자리에서 `배방읍` 이 이름 후보가 됨

7-5. 오탐 (65건) — 출처별

출처	건수	사례	원인
규칙	37	`소명자:` 10, `배송지:` 9, `위임인:` 8, `송금인:` 7, `심사역` 3	**새 문서 유형의 서식 항목 이름**. `소명+자`, `위임+인` 처럼 사전 단어 + 접미사가 성씨 글자로 시작해 이름 후보가 됨(줄 맨 앞 `이름:` 규칙·명사 덩어리 규칙)
규칙	8	`정다운 금융 생활을 위해`	형용사 `정다운` 을 Kiwi가 고유명사로 분석 (같은 글자의 실제 이름도 있음)
토큰	6	출장보고 표의 `미르보안` 5, 분쟁조정 `미르【보안】` 1	회사 이름을 사람으로
토큰 (+규칙 2)	6	경조사공지 `조모상` 4, `장인상` 2	부고 단어를 이름으로
토큰	5	`사건 번호: 경찰청【2026-822765】` → 전화 2·계좌 2·주민 1	**새 문서 유형(피해접수)의 사건번호**. 연도-일련번호 모양
토큰	2	`(내선【1067】)` → 전화	내선번호
토큰	1	`결제 알림【미수】신`	`미수신` 의 일부를 이름으로

7-6. 새로 드러난 오류 유형 (dev·test에서 보지 못한 것)

유형	예	dev·test에 없던 이유
서식 항목 이름 오탐	`소명자:`, `위임인:`, `송금인:`	법인카드소명·대리인위임확인·해외송금접수 등 새 문서 유형의 서식
외자 이름 경계·미탐	`안윤이`, `전 찬`, `신설`	dev·test 외자 비중 5% → holdout 13%
한 글자 이름	`린 님`	dev·test에 0건
주소 앞 우편번호	`(05299) 서울특별시 …`	dev·test 주소는 우편번호 없음
지번 `읍 + 번지`	`배방읍 252-4`	dev·test 주소는 도로명 위주
계좌 마지막 1자리	`056-75-340175-9`	dev·test 계좌는 한 가지 형식
사건번호·내선	경찰청 `2026-822765`, 내선 `1067`	피해접수 문서 유형이 새로 등장
회사·부고 단어	`미르보안`, `조모상`	출장보고·경조사공지 문서 유형이 새로 등장

7-7. 선정 탐지기의 강점과 한계

강점

- **놓치지 않음이 유지됨**: 처음 보는 문서 유형 19종에서도 미탐 3개, mask_rec 0.993 (test 1.000)
- **새 번호 형식에 강함**: 국제번호 `+82`, 공백·붙여쓰기 카드·주민번호, 은행별 계좌 자릿수, 지번 주소 대부분을 잡음(카드·주민·전화 형식 변형 재현율 1.000) — 엣지 케이스·일상 문서로 미리 대비한 효과

- **규칙과 토큰이 서로 메움**: 규칙 단독 미탐 72 → 합집합 3. 외자 이름 재현율 규칙 0.289 → 합집합 0.947. 토큰 계좌 형식 변형 0.696 → 합집합 0.957
- 처리 속도 문서당 48ms, 결과 일관성 100%

한계

- **정밀도**: 오탐 65건(정밀도 0.912). 새 문서 유형의 서식 항목 이름(규칙), 회사·부고·사건번호(토큰). 실전 2에서 불필요한 가명 토큰이 생겨 검색 품질에 영향을 줄 수 있다.
- **외자·한 글자 이름**: 일반 단어와 같은 외자(`신설`), 띄어 쓴 외자(`전 찬`), 한 글자 이름(`린`)은 문맥 단서가 없으면 못 잡는다.
- **경계**: 주소 앞 우편번호, 이름 뒤 `이`·`드림` → 가려지기는 하지만 실전 2에서 같은 사람이 다른 토큰이 될 수 있다.
- **규칙의 문맥 의존**: 새 서식(`항목명:`)에서 규칙이 오히려 오탐을 만든다 — dev·test 서식에 맞춘 줄 맨 앞 `이름:` 규칙의 부작용.

7-8. 개선 후보와 판단

#	대상	개선	적용
1	규칙 오탐 37	`항목명:` 앞 단어가 서식 항목 접미사(자·인·역·지 등)로 끝나면 이름 아님	⑧에서 적용
2	토큰 오탐	부고 단어, 회사 이름 끝말, 사건·접수번호 문맥과 `내선` 뒤 번호 제거	⑧에서 적용
3	경계	주소 앞 우편번호 포함, 이름 뒤 `드림`·주격 `이` 제거	⑧에서 적용
4	미탐·라벨	띄어 쓴 외자 필드 이름, 필드 추가(수취인 등), 계좌 마지막 1자리, `읍` + `번지` 지번 주소	⑧에서 적용
—	한 글자 이름 `린`, 형용사 `정다운`	고치면 일반 글자·단어를 이름으로 잡을 위험이 커서 **한계로 남김**	적용 안 함