실전 1 보고서 — 요약 및 결론

> - **과제**: 금융사 사내 문서에서 개인정보 7종을 찾는 탐지기를 규칙 기반·토큰 분류·LLM 세 방식으로 비교하고, 운영에 쓸 탐지기를 근거 있게 고른다.
> - **데이터**: 제공 `pii_synth_finance` dev 100건(정답 548개) · test 200건(정답 1,165개) / 추가 시험 데이터: 엣지 케이스 64건(정답 116개), 일상 문서 1,983건(정답 3,375개)
> - **채점**: 멘토 제공 `run_compare.py` (strict·partial 정밀도/재현율/F1, mask_rec, 라벨별·어려운 사례 재현율, 일관성)
> - **작성**: 2026-10-23 · 저장소 `hosung` 브랜치 `실전프로젝트1/` · 작업 기록 전체는 `worklog.md`

보고서 구성: 0 요약 및 결론 · ① 데이터 관찰 리포트 · ② 방식별 비교표 · ③ 오류 유형 분석 · ④ 탐지기 선정 근거 · ⑤ 개선 과정과 데이터 사용 기록 (`report/` 폴더)

요약

항목	결론
운영 탐지기	**규칙 기반(정규식 + Kiwi) + 토큰 분류 모델(atonlee) 전체 합집합**
선정 이유	모든 시험 데이터에서 놓친 개인정보가 가장 적음 — test mask_rec **1.000**, 처음 보는 일상 문서 mask_rec **0.988**. CPU만으로 문서당 약 0.1초(1만 건 약 19분), 결과가 항상 같고, 원문이 외부로 나가지 않음
LLM의 역할	**탐지에는 쓰지 않고 RAG 답변 생성에서만 사용** (마스킹된 텍스트만 전달). LLM을 더해도 재현율은 오르지 않고, 약 16배 이상 느리며, 원문을 외부로 보내야 함
우선 지표	재현율·mask_rec(놓치지 않기) → 정밀도는 하한선 0.90 → 속도 → 일관성
데이터 사용	개선은 dev(와 추가 데이터의 개선용 절반)로만, test는 중간 확인. 초기에 test 오류를 본 이력이 있어 그대로 밝힘(⑤ 개선 과정과 데이터 사용 기록)

한계와 다음 단계

- **holdout 147건을 받지 못했다.** 받으면 지금 설정 그대로 한 번만 채점한다(`run_detect.py --split` 추가).
- **정밀도 개선 여지**: 합집합의 오탐 대부분은 토큰 모델의 구어체·상품명 오탐(`달래`, `하린`)이다. 문맥 없는 이름 후보에 신뢰도를 매겨 "규칙과 모델이 모두 동의할 때만" 채택하는 방식을 검토한다.
- **추가 데이터의 정답 품질**: 일상 문서 정답 검수(44건)를 팀 기준으로 마치면 수치가 더 정확해진다.
- **LLM 하이브리드는 처음 보는 문서에서 재지 않았다.** 다만 속도·외부 전송·일관성 문제는 데이터와 무관하다.
- 실전 2로 넘길 것: 같은 사람의 다른 표기(`윤 선영` / `윤선영`, `010.0349.2063` / `01003492063`) 정규화, 동명이인 구분, 메신저 호격 조사(`은영이`) 제거.

재현 방법과 파일 위치

```
cd 실전프로젝트1
python -X utf8 run_detect.py --detector rules --split test
python -X utf8 run_detect.py --detector atonlee --split test
python -X utf8 make_union.py --out preds/combined/rules+atonlee_test.jsonl preds/rules_test.jsonl
preds/atonlee_test.jsonl
python -X utf8 run_compare.py --gold data/pii_synth_finance_test.jsonl --pred
rules+atonlee=preds/combined/rules+atonlee_test.jsonl --out results/check
```

```
python -X utf8 experiments/compare_systems.py          # 규칙 / 토큰 / 규칙+토큰 비교표
python -X utf8 tools/make_compare_table.py test --rank  # LLM 7종 비교표 (팀원)
```

내용	위치
작업 기록 전체	`worklog.md`
보고서 PDF 다시 만들기	`python -X utf8 tools/build_report.py` (PowerShell에서 실행, `report/*.md` → `report/*.pdf`)
탐지기	`detectors/rule_based.py` (규칙), `detectors/token_cls.py` · `hf_ner.py` (토큰), `detectors/llm*.py` (LLM)
후처리 (대표번호·장소 주소·경계)	`postprocess.py`
비교표	`results/system_comparison.csv`, `results/final_<데이터>/summary.csv`
오류 목록	`results/final_<데이터>/errors_<방식>.csv`
분석기 비교	`results/analyzer_comparison.csv`
추가 데이터	`data/edge_cases.jsonl`, `data/generated/` (생성 프롬프트: `tools/generate_synthetic.py`)
팀원 비교 문서	`docs/team_baek/` (LLM 7종)