실전 1 보고서 1부 ① 데이터 관찰 리포트

> - **과제**: 금융사 사내 문서에서 개인정보 7종을 찾는 탐지기를 규칙 기반·토큰 분류·LLM 세 방식으로 비교하고, 운영에 쓸 탐지기를 근거 있게 고른다.
> - **데이터**: 제공 `pii_synth_finance` dev 100건(정답 548개) · test 200건(정답 1,165개) / 추가 시험 데이터: 엣지 케이스 64건(정답 116개), 일상 문서 1,983건(정답 3,375개) / **멘토 holdout 187건(정답 912개)**
> - **채점**: 멘토 제공 `run_compare.py` (strict·partial 정밀도/재현율/F1, mask_rec, 라벨별·어려운 사례 재현율, 일관성)
> - **작성**: 2026-10-23, 수치 갱신 2026-10-26 (탐지기 v8) · 저장소 `hosung` 브랜치 `실전프로젝트1/` · 작업 기록 전체는 `worklog.md`

보고서 구성: 0 요약 및 결론 · **1부** ① 데이터 관찰 리포트 · ② 방식별 비교표 · ③ 오류 유형 분석 · ④ 탐지기 선정 근거 · **2부** ⑤ Holdout 데이터 관찰 · ⑥ Holdout 성능 · ⑦ Holdout 오류 분석 · ⑧ Holdout 개선 내역 · 부록 개선 과정과 데이터 사용 기록 (`report/` 폴더)

> **1부 수치 기준**: holdout 오류 분석 후 고친 **탐지기 v8**의 값이다. 이후 v9(부록 A-4)에서 dev·test·엣지 결과는 바뀌지 않았고, 일상 문서 평가용만 조금 올랐다(규칙 + 토큰 strict F1 0.956 → 0.961, mask_rec 0.988 → 0.989). holdout을 보기 전(v7) 값과 개선 전후 비교는 ⑥ Holdout 성능·⑧ Holdout 개선 내역 참고. 1부의 '일상 문서'는 팀이 만든 생성 문서(개선용 synth_dev / 평가용 synth_holdout)이고, 멘토가 준 holdout과 다르다.

팀원이 문서를 직접 읽으며 관찰한 내용을 정리했고, 개수는 정답 파일(라벨별로 모은 `data/gold_by_label/*.csv`)로 확인했다.

1-1. 데이터 구성

항목	dev	test
문서 수	100	200
정답 개인정보 수	548	1,165
문서 유형	14종 (대출상담, 카드분실, 업무메일, 회의록, 민원, 사내메신저 등)	14종
템플릿 수	23	23 (**dev와 전부 같음**)
등장 인물	66명	72명 (그중 test에만 나오는 인물 7명)
개인정보 없는 문서	18	32
문서 평균 길이	283자	277자

- **test의 템플릿 23종이 모두 dev에 있다.** test 점수는 "처음 보는 문서" 성능이 아니어서 낙관적일 수밖에 없다.
- 노션에는 라벨이 8종으로 되어 있으나, 멘토 안내대로 **organization을 빼고 7종**으로 평가했다.

1-2. 라벨별 개수

라벨	dev	test	합계	비율
person (이름)	340	775	1,115	**65%**
phone_number (전화번호)	82	168	250	15%
email (이메일)	33	80	113	7%
address (주소)	41	63	104	6%
resident_registration_number (주민등록번호)	20	27	47	3%

라벨	dev	test	합계	비율
account_number (계좌번호)	16	27	43	3%
card_number (카드번호)	16	25	41	2%

→ **이름이 3분의 2**라 이름 탐지가 성패를 좌우한다. 주민·계좌·카드번호는 수가 적어(25~47개) 라벨별 점수가 1~2개 차이로 크게 흔들린다.

1-3. 표기 형태

이름 표기

표기 형태	dev	test	예
전체 이름 (full)	298	680	`윤선영`
띄어 쓴 이름 (spaced)	27	51	`윤 선영`
이름만 (given)	15	44	`소율 씨`, `승현아`

이름 바로 뒤에 붙은 글자 (test): 공백·기호 655, `님` 34, `은` 23, `입(니다)` 21, `이` 19, `아` 11, `는` 5, `랑` 3 → 조사·호칭이 붙은 이름이 약 15%. 정답은 조사를 뺀 이름만 표시한다(`윤선영은` → `윤선영`).

전화번호 형식 (test)

형식	개수	예
010-0000-0000	107	하이픈
01000000000	19	붙여 쓰기
02-0000-0000	14	서울 지역번호
010.0000.0000	11	점
010 0000 0000	8	공백
02 0000 0000 / 0200000000 / 02.0000.0000	4 / 3 / 2	지역번호 변형

주민·계좌·카드번호는 형식이 하나뿐이다: 주민 `999999-9999999`(47개 모두), 계좌 `999-999999-99`(43개), 카드 `9999-9999-9999-9999`(41개). 또한 **모두 일부러 가짜로 만든 값**이다: 주민번호 47개 모두 체크섬 불일치, 카드번호 41개 모두 Luhn 검증 실패(앞자리도 존재하지 않는 `9410`). 그래서 이 데이터에서는 체크섬으로 거르면 정답을 전부 놓친다. 실제 운영에서는 신뢰도를 올리는 신호로 쓸 수 있다.

1-4. 어려운 사례 태그 분포 (문서 수)

태그	dev	test	의미
josa_attached	22	52	조사가 붙은 이름 (`윤선영은`)
spaced_name	27	51	띄어 쓴 이름
homonym	23	49	동명이인 (`김민준` 2명 등)
phone_format_variant	24	41	전화번호 형식 변형
surname_title_unlabeled	17	40	정답 없는 성+직함 (`허 부장님`)
no_pii	18	32	개인정보 없는 문서
given_only	13	31	이름만 쓴 경우
decoy_company_phone	13	24	대표번호 미끼 (`1599-0000`)
decoy_words	10	20	이름 같은 단어 미끼 (한결같이)
decoy_numbers	5	5	민원번호 미끼 (`202611910266`)

1-5. 관찰에서 예상한 어려운 점과 추가 시험 데이터

관찰	예상한 어려움	대응
이름이 65%, 조사·띄어쓰기·이름만 표기	규칙이 이름 경계·이름만 쓴 경우를 놓침	형태소 분석(Kiwi), 호칭·필드·문서 안 이름 퍼뜨리기 규칙
템플릿 23종이 dev·test 공통	dev 문구에 맞춘 규칙이 처음 보는 문서에서 무너짐	문맥 규칙을 끈 실험으로 하락 폭 추정(재현율 약 8%p)
형식이 단조로움 (전화 010·02만, 계좌·주소 한 형식)	실제 문서의 다양한 형식을 시험할 수 없음	**엣지 케이스 64건**(지역번호·070·안심번호·+82, 은행별 계좌, 지번·읍면 주소, 외자·복성·외국인 이름 등)을 직접 작성
금융사 문서만 있음	일상 문서(상담·환불·배송·예약 등)에서의 성능을 모름	**일상 문서 1,983건**을 OpenAI gpt-4.1로 생성 (카테고리 20 × 문체 5). 규칙 내용을 프롬프트에 넣지 않았고, **절반(994건)은 끝까지 오류를 보지 않는 holdout**으로 둠

추가 데이터의 한계: 엣지 케이스는 규칙 작성자가 써서 점수가 낙관적이고, 일상 문서 정답은 생성 모델이 표시해서 표시 누락 등 오류가 섞여 있다(검수 후보 44건, `results/synth_qc_candidates.csv`). 그래서 이 데이터들의 점수는 **절대값보다 방식 간 비교**로 쓴다.

1-6. 팀 라벨 기준

판단 원칙: **"이 값으로 특정한 사람을 알아낼 수 있는가"**

표현	판단	이유
`김 과장`, `허 부장님` (성 + 직함)	**개인정보 아님**	한 사람으로 특정되지 않음. 잡으면 실전 2에서 서로 다른 '김 과장'들이 한 토큰으로 합쳐짐 (데이터셋 정답 기준과 같음)
`소율 씨`, `승현아` (이름만)	개인정보	문서 안에서 특정인을 가리킴
조사·호칭 (`윤선영은`, `김민수님`)	범위에서 뺌	이름만 표시
회사 대표번호 `1599-0000`, `1588-…`, 080	**개인정보 아님**	콜센터로 연결될 뿐 상담사·고객 누구도 특정하지 않음
직원 직통번호 `02-3961-1452`	개인정보 (그 직원)	한 사람에게 연결됨
장소 주소 (웨딩홀·장례식장·회식 장소 등)	**개인정보 아님**	누구나 찾아가는 장소. 단, 판단이 애매하면 가림(아래)
집 주소, 배송지, 동·호수가 있는 주소	개인정보	`직거래 … 902동 505호에서` 처럼 장소 문맥이어도 동·호수가 있으면 집일 수 있음
휴대폰 번호를 계좌로 쓰는 경우 (토스 등)	계좌	`계좌 · 은행` 바로 뒤일 때. 어느 쪽이든 가려지므로 mask_rec에는 영향 없음
일부를 가린 값 `900512-2******`	개인정보	보이는 부분만으로도 정보가 드러남
계좌 앞 은행 이름	범위 밖	번호만 표시 (데이터셋 기준)
회사·기관·부서·상품명	개인정보 아님	organization 라벨 제외

장소 주소는 **비대칭으로** 판단한다: 장소를 뜻하는 말(`장소:`, `식장`, `빈소`, `회식` …)이 확실히 있고, 개인을 가리키는 말(`주소`, `자택`, `배송` …)과 동·호수가 없을 때만 뺀다. 집 주소를 놓치는 것이 장소 주소를 가리는 것보다 훨씬 위험하기 때문이다.