실전 1 보고서 ② 방식별 비교표

> - **과제**: 금융사 사내 문서에서 개인정보 7종을 찾는 탐지기를 규칙 기반·토큰 분류·LLM 세 방식으로 비교하고, 운영에 쓸 탐지기를 근거 있게 고른다.
> - **데이터**: 제공 `pii_synth_finance` dev 100건(정답 548개) · test 200건(정답 1,165개) / 추가 시험 데이터: 엣지 케이스 64건(정답 116개), 일상 문서 1,983건(정답 3,375개)
> - **채점**: 멘토 제공 `run_compare.py` (strict·partial 정밀도/재현율/F1, mask_rec, 라벨별·어려운 사례 재현율, 일관성)
> - **작성**: 2026-10-23 · 저장소 `hosung` 브랜치 `실전프로젝트1/` · 작업 기록 전체는 `worklog.md`

보고서 구성: 0 요약 및 결론 · ① 데이터 관찰 리포트 · ② 방식별 비교표 · ③ 오류 유형 분석 · ④ 탐지기 선정 근거 · ⑤ 개선 과정과 데이터 사용 기록 (`report/` 폴더)

2-1. 비교한 방식

방식	구성
규칙 기반	정규식(전화·이메일·주민·계좌·카드·주소) + 형태소 분석기 Kiwi + 일반 성씨 목록 + 필드·호칭·직급·서명 문맥 규칙 + 문서 안 이름 퍼뜨리기 + 후처리(대표번호·장소 주소 제외). 데이터셋 인물 목록은 쓰지 않음
토큰 분류	`atonlee/koelectra-ko-pii-ner` (KoELECTRA-small, 14M, Apache-2.0) + 같은 후처리. 팀원이 7개 모델을 비교한 뒤 속도·재현율로 선택(② 방식별 비교표 2-6)
규칙 + 토큰	두 결과의 전체 합집합, 위치가 겹치면 규칙 쪽 경계 우선
LLM	OpenAI gpt-4.1-mini, temperature 0, JSON 출력. LLM은 (값, 라벨)만 돌려주고 위치는 코드가 원문에서 찾음. 팀원이 7개 모델을 비교(② 방식별 비교표 2-5)

2-2. 지표와 우선순위

순위	기준	지표
1	놓치지 않기	**mask_rec**(정답 글자 중 가려진 비율), 재현율 — 놓친 개인정보는 벡터 DB·LLM으로 그대로 흘러감
2	정밀도 하한선	strict 정밀도 **0.90 이상** — 너무 많이 가리면 검색·분석 품질이 떨어짐
3	속도	CPU 기준 문서 1건 처리 시간, 1만 건 환산 (모델 로딩 제외)
4	일관성	같은 문서를 3번 돌렸을 때 결과가 같은 문서 비율

2-3. 제공 데이터 비교표 (test 200건)

방식	strict P	strict R	strict F1	partial R	mask_rec	ms/문서	1만 건	일관성(3회)	원문 외부 전송
규칙 기반	0.997	0.988	0.993	0.990	0.997	10.0	약 2분	100%	없음
토큰 (atonlee)	0.947	0.964	0.955	0.986	0.989	102.0	약 17분	100%	없음
규칙 + 토큰	0.968	**0.997**	0.982	**1.000**	**1.000**	112.0	약 19분	100%	없음
LLM (gpt-4.1-mini)	0.996	0.963	0.979	0.967	0.988	1,291.7	약 3.6시간	93.0%	**있음**

- dev(100건)에서도 순위가 같음: mask_rec 규칙 0.999, 토큰 0.988, 규칙 + 토큰 1.000, LLM 0.986
- LLM 일관성: test 3회 실행 평균 Jaccard 0.993, 결과가 완전히 같은 문서 93.0% (dev는 88.0%). temperature 0 이어도 결과가 달라짐
- 1만 건은 문서를 하나씩 순서대로 처리할 때 기준. LLM은 8건씩 동시에 보내면 약 30분이지만 문서 1건 지연은 그대로이고 API 요청 한도·비용에 묶임

2-4. 처음 보는 문서와 엣지 케이스

일상 문서 holdout (994건, 정답 1,732개, 오류를 한 번도 보지 않음)

방식	strict P	strict R	strict F1	mask_rec	ms/문서	1만 건
규칙 기반	0.949	0.958	0.954	0.972	4.3	1분 미만
토큰 (atonlee)	0.908	0.947	0.927	0.984	78.9	약 13분
규칙 + 토큰	0.909	**0.979**	0.942	**0.988**	83.2	약 14분

엣지 케이스 (64건, 정답 116개): mask_rec 규칙 0.998 · 토큰 0.921 · 규칙 + 토큰 **1.000**

→ 규칙은 제공 데이터에 강하지만 처음 보는 문서에서 2.8%를 놓치고, 토큰은 반대로 처음 보는 문서에 강하지만 형식이 특이한 번호(안심번호·휴대폰 계좌·외국인등록번호 등)에 약하다. **합치면 모든 데이터에서 가장 적게 놓친다.**

2-5. 라벨별 재현율 (정밀도)

라벨	규칙 test	토큰 test	규칙+토큰 test	LLM test	규칙 holdout	토큰 holdout	규칙+토큰 holdout
person	0.985 (1.00)	0.985 (0.96)	**1.000** (0.96)	0.952 (1.00)	0.958 (0.93)	0.989 (0.97)	**0.999** (0.91)
phone_number	1.000 (1.00)	0.982 (1.00)	1.000 (1.00)	0.988 (0.99)	0.986 (0.99)	1.000 (0.91)	**1.000** (0.95)
email	1.000 (1.00)	1.000 (1.00)	1.000 (1.00)	1.000 (1.00)	0.991 (0.99)	0.991 (0.98)	0.991 (0.98)
address	1.000 (1.00)	1.000 (1.00)	1.000 (1.00)	1.000 (1.00)	0.958 (0.98)	0.964 (0.89)	0.964 (0.92)
주민등록번호	1.000 (1.00)	1.000 (0.96)	1.000 (1.00)	1.000 (1.00)	0.939 (0.99)	0.963 (**0.66**)	**0.988** (0.70)
account_number	1.000 (1.00)	0.963 (0.96)	1.000 (1.00)	1.000 (1.00)	0.983 (0.95)	**0.731** (0.92)	0.983 (0.94)
card_number	1.000 (1.00)	1.000 (1.00)	1.000 (1.00)	1.000 (1.00)	0.966 (1.00)	0.949 (0.93)	0.966 (0.98)

(partial 기준. holdout 주소 재현율 0.96은 생성 정답이 장소 주소를 표시한 경우를 팀 기준대로 가리지 않았기 때문, 3-4 참고)

어려운 사례 재현율 (test): 이름만 쓴 경우(form=given, 44개) 규칙 0.750 · 토큰 1.000 · **규칙 + 토큰 1.000** · LLM 0.455 / 조사 부착 문서 규칙 0.968 · 토큰 0.968 · 규칙 + 토큰 1.000 · LLM 0.930

미끼 오탐 (test): 대표번호 미끼 문서(24) 규칙 0 · 토큰 8 · 규칙 + 토큰 8 · LLM 0 / 개인정보 없는 문서(32) 규칙 0 · 토큰 8 · 규칙 + 토큰 8 · LLM 0

2-6. 팀원 비교 결과 — 토큰 분류 모델 7종 (박지훈, test, 모델 단독)

모델	크기	라이선스	strict F1	mask_rec	ms/문서	대표번호 미끼 오탐
veil (`1T/veil-pii-ko-lite`)	112M	Apache-2.0	0.938	0.990	128	37
seongyeon (`ko-pii-ner-roberta-base`)	110M	CC-BY-SA-4.0	0.869	0.912	151	10
kpf (`kpfbert-kdpii`)	113M	MIT	0.750	0.952	144	53
atonlee (`koelectra-ko-pii-ner`)	**14M**	Apache-2.0	0.885	0.989	**25**	32
dlp (`kr-dlp-ner-roberta-large`)	336M	Apache-2.0	0.926	0.976	552	16
e5 (`korean-pii-e5-base`)	278M	MIT	0.798	0.949	146	14
bccard (`MoAI-Privacy-Filter-INT8`, 멘토 지정 기준 모델)	1.4B MoE	Apache-2.0	0.819	0.903	368	20

- 팀원 측정(후처리 없음, 팀원 PC). **atonlee는 mask_rec이 veil과 거의 같으면서 5~20배 빠르고 가장 작아** 선택했다. 우리 후처리(대표번호·경계 보정)를 붙이면 미끼 오탐이 32 → 8로 줄어든다.
- 기준 모델 bccard는 계좌번호를 운전면허번호로 혼동해 계좌 재현율 0.185, 단독 재현율 0.773으로 낮았다.
- 모델 카드 점수와 비교: atonlee 자체 보고 boundary F1 88.1%·type F1 94.2%는 우리 데이터 결과와 비슷했다. 금융 개인정보 데이터(`BCCard/pii-masking-openpii-finance`)로 학습해 분야가 맞기 때문으로 본다. 반면 PIILOT 등 평가 데이터를 밝히지 않은 모델은 카드 점수(F1 95.9%)와 우리 점수(0.636)가 크게 달랐다.

2-7. 팀원 비교 결과 — LLM 7종 (baek0046, test, 후처리 없음)

방식	mask_rec	strict R	strict P	미끼 오탐	ms/문서	일관성(3회)
LLM gpt-5.4-mini	0.999	0.995	0.967	9	1,219	81.0%
LLM gpt-6-luna	0.990	0.995	0.980	4	1,704	86.0%
LLM gpt-5.6-luna	0.987	0.991	0.989	1	1,606	93.5%
LLM HCX-007 (HyperCLOVA X)	0.987	0.950	0.934	11	2,629	77.5%
LLM gpt-5.5	0.983	0.989	1.000	0	1,778	98.5%
LLM gpt-4.1-mini	0.981	0.981	0.984	7	1,310	95.5%
LLM DASH-002 (HyperCLOVA X)	0.667	0.585	0.900	11	5,899	—
규칙 + gpt-5.5 (LLM 하이브리드 최고)	1.000	0.998	0.997	0	1,781	100%
규칙 + HCX-007	1.000	0.996	0.955	11	2,631	88.0%

다시 계산: `python -X utf8 tools/make_compare_table.py test --rank` (팀원 도구, 팀원 PC 측정 시간)

2-8. 시간 측정 조건

- 같은 PC의 CPU, 문서를 하나씩 처리, 모델 로딩 시간 제외(첫 문서로 워밍업)
- 같은 날 다른 시각에 쟀을 때 다른 앱 부하로 **약 2배 차이**가 났다. 표에는 느리게 나온 값을 보수적으로 넣었다(오전 측정: 규칙 4.6ms, 토큰 50.5ms, 규칙 + 토큰 55.1ms).
- 일상 문서는 평균 78자로 제공 문서(280자)보다 짧아 문서당 시간도 짧다.