실전 1 보고서 ③ 오류 유형 분석

> - **과제**: 금융사 사내 문서에서 개인정보 7종을 찾는 탐지기를 규칙 기반·토큰 분류·LLM 세 방식으로 비교하고, 운영에 쓸 탐지기를 근거 있게 고른다.
> - **데이터**: 제공 `pii_synth_finance` dev 100건(정답 548개) · test 200건(정답 1,165개) / 추가 시험 데이터: 엣지 케이스 64건(정답 116개), 일상 문서 1,983건(정답 3,375개)
> - **채점**: 멘토 제공 `run_compare.py` (strict·partial 정밀도/재현율/F1, mask_rec, 라벨별·어려운 사례 재현율, 일관성)
> - **작성**: 2026-10-23 · 저장소 `hosung` 브랜치 `실전프로젝트1/` · 작업 기록 전체는 `worklog.md`

보고서 구성: 0 요약 및 결론 · ① 데이터 관찰 리포트 · ② 방식별 비교표 · ③ 오류 유형 분석 · ④ 탐지기 선정 근거 · ⑤ 개선 과정과 데이터 사용 기록 (`report/` 폴더)

예측과 정답을 하나씩 비교한 오류 목록: `results/final_<데이터>/errors_<방식>.csv` (앞뒤 15자 문맥 포함)

3-1. 오류 건수

방식	데이터	미탐	오탐	경계 오류	라벨 오류
규칙 기반	test	12	1	2	0
토큰 (atonlee)	test	16	35	26	0
규칙 + 토큰	test	**0**	36	3	0
LLM (gpt-4.1-mini)	test	**39**	1	4	0
규칙 기반	holdout	55	72	17	0
토큰 (atonlee)	holdout	19	90	35	38
규칙 + 토큰	holdout	**9**	142	21	7

3-2. 방식별 대표 사례와 원인

규칙 기반 — 미탐형 약점 (문맥 없는 이름)

유형	사례 (【 】 = 정답)	원인
미탐	`메신저 알겠어. 【현준】이랑 같이 정리해서 올릴게` (test 미탐 12건 중 다수)	성 없이 처음 나오는 이름. 호칭·필드 같은 문맥 단서가 없고 `현준이랑` 은 일반 단어와 구분이 안 됨
미탐	`카드운영팀 【정현준】` (인사 발령 목록)	부서명 뒤에 공백 하나로 붙은 이름. 필드·직급 단서 없음
경계	`【은영】이랑` → `은영이`	호격·조사 `이` 를 이름의 일부로 퍼뜨림
오탐	`【고객명】: 이재원` → `고객명` 을 이름으로	형태소 분석기가 사전에 없는 단어로 보고 성씨 글자(`고`)로 시작해 이름 후보가 됨
오탐 (일상 문서)	`배송지`, `장인상` (부고), `신청일`, `서울숲`	같은 원인. 장소 접미사·합성어 필터로 대부분 해결(⑤ 개선 과정 5-3의 v6)

형태소 분석기의 한계도 드러났다: Kiwi는 `오세린` 을 `오`(숫자 5)+`세`(나이)+`린`("다섯 살")으로, `이우리` 를 `이`(감탄사)+`우리` 로, `백승훈님` 을 `백`(숫자 100)+`승`+`후`+`ㄴ` 으로 분석했다. 그래서 품사만으로 이름을 판단하지 않고, 필드·호칭·말하는 사람 형식 같은 문맥 규칙으로 보완했다. 분석기 5종 비교(Kiwi·Komoran·Kkma·Hannanum·Okt)에서도 **사전에 없는 단어를 표시해 주는 Kiwi**가 이름 재현율 0.985로 가장 높았다(Okt·Hannanum은 0.2 미만).

토큰 분류 (atonlee) — 오탐·경계형 약점

유형	사례	원인
오탐	`내일까지 보고서【달래】` (12건)	구어체 동사 `달래` (달라고 해)를 이름으로 봄
오탐	`하린 포인트 카드 의 하린` (11건), 회사명 `미르보안` (6건)	상품·회사 이름이 사람 이름처럼 생김
경계	`정하은 → 정하`, `손하은 책임 → 직함까지`, 주소 뒤 조사 `…1301호로`	서브워드 조각 단위 예측이라 이름 끝·조사 경계가 흔들림
미탐	붙여 쓴 지역번호 `0239644249`	학습 데이터에 드문 형식
라벨 오류 (일상 문서)	점 구분 계좌 `003.004900.35793`, 2묶음 계좌를 다른 라벨로	계좌 형식을 좁게 학습 → holdout 계좌 재현율 0.731
정밀도 (일상 문서)	주문·접수번호 등 13자리 숫자를 주민번호로	holdout 주민번호 정밀도 0.66

LLM (gpt-4.1-mini) — 미탐형 약점 (지시 과잉 적용·비결정성)

유형	사례	원인
미탐	메일 서명의 직원 직통번호 `02-3961-1452`	"대표번호·내선번호 제외" 지시를 직통번호까지 넓혀 적용
미탐	`【상훈】아, 오늘 회의 자료…` (이름만 부르기, given 재현율 0.455)	메신저 호칭을 이름으로 보지 않음
미탐	`리스크관리팀【허수아】` (3회 실행 모두 반복 누락)	같은 이름을 일관되게 놓침
경계	`【서연】아 → 서연아`	호격 조사를 이름에 포함
오탐	내선 `【5647】`을 전화번호로	내선번호 판단 오류

규칙 + 토큰 — 미탐 0, 오탐은 토큰 쪽에서 들어옴

- test 미탐 0: 규칙이 놓친 이름만 쓴 경우를 토큰이 잡고, 토큰이 놓친 붙여 쓴 번호를 규칙이 잡음 (서로 약점이 겹치지 않음)
- 오탐 36건은 대부분 토큰의 오탐(`달래`, `하린`, `미르보안`)이 그대로 들어온 것 → 정밀도 0.968 (하한선 0.90 위)
- 경계 3건은 규칙의 `은영이` 유형

3-3. 일상 문서에서만 보인 오류

오류	예	판단
계좌 앞 은행 이름 경계	생성 정답 `우리은행 1000-202-340001`, 탐지 `1000-202-340001`	정답 기준 차이 (데이터셋은 번호만). strict에서만 감점
장소 주소	장례식장·파티룸 주소를 생성 정답이 표시	팀 기준상 가리지 않는 게 맞음
사업자등록번호·송장번호를 계좌로	`사업자등록번호 123-45-67890`	v6 규칙에서 문맥 단어로 제외
날짜가 맞지 않는 주민번호	`820515-0234521` (뒷자리 0)	`주민번호` 문맥이 있으면 6-7자리를 주민번호로 보도록 v6에서 보완

3-4. 정답 데이터 자체의 문제

- 일상 문서 정답은 생성 모델이 표시해 **표시 누락**이 있다(`예금주: 정세림`, `김미영 부장님`, 집 주소 등 → 탐지기가 맞게 잡아도 오탐으로 채점). 검수 후보 44건을 뽑았고(`results/synth_qc_candidates.csv`), 팀 기준(장소 주소 제외)으로 정답을 다시 맞추면 holdout 정밀도와 주소 재현율이 더 정확해진다.
- 제공 데이터에는 `김 과장` 같은 성+직함이 정답에 없다(dev 17, test 40건). 팀 기준과 같아 오탐으로 처리했다.