실전 1 보고서 1부 ③ 오류 유형 분석

> - **과제**: 금융사 사내 문서에서 개인정보 7종을 찾는 탐지기를 규칙 기반·토큰 분류·LLM 세 방식으로 비교하고, 운영에 쓸 탐지기를 근거 있게 고른다.
> - **데이터**: 제공 `pii_synth_finance` dev 100건(정답 548개) · test 200건(정답 1,165개) / 추가 시험 데이터: 엣지 케이스 64건(정답 116개), 일상 문서 1,983건(정답 3,375개) / **멘토 holdout 187건(정답 912개)**
> - **채점**: 멘토 제공 `run_compare.py` (strict·partial 정밀도/재현율/F1, mask_rec, 라벨별·어려운 사례 재현율, 일관성)
> - **작성**: 2026-10-23, 수치 갱신 2026-10-26 (탐지기 v8) · 저장소 `hosung` 브랜치 `실전프로젝트1/` · 작업 기록 전체는 `worklog.md`

보고서 구성: 0 요약 및 결론 · **1부** ① 데이터 관찰 리포트 · ② 방식별 비교표 · ③ 오류 유형 분석 · ④ 탐지기 선정 근거 · **2부** ⑤ Holdout 데이터 관찰 · ⑥ Holdout 성능 · ⑦ Holdout 오류 분석 · ⑧ Holdout 개선 내역 · 부록 개선 과정과 데이터 사용 기록 (`report/` 폴더)

> **1부 수치 기준**: holdout 오류 분석 후 고친 **탐지기 v8**의 값이다. 이후 v9(부록 A-4)에서 dev·test·엣지 결과는 바뀌지 않았고, 일상 문서 평가용만 조금 올랐다(규칙 + 토큰 strict F1 0.956 → 0.961, mask_rec 0.988 → 0.989). holdout을 보기 전(v7) 값과 개선 전후 비교는 ⑥ Holdout 성능·⑧ Holdout 개선 내역 참고. 1부의 '일상 문서'는 팀이 만든 생성 문서(개선용 synth_dev / 평가용 synth_holdout)이고, 멘토가 준 holdout과 다르다.

예측과 정답을 하나씩 비교한 오류 목록: `results/final_<데이터>/errors_<방식>.csv` (앞뒤 15자 문맥 포함)

3-1. 오류 건수

방식	데이터	미탐	오탐	경계 오류	라벨 오류
규칙 기반	test	12	0	2	0
토큰 (atonlee)	test	16	26	22	0
규칙 + 토큰	test	**0**	26	3	0
LLM (gpt-4.1-mini)	test	**39**	1	4	0
규칙 기반	일상 문서 (synth_holdout)	56	58	17	0
토큰 (atonlee)	일상 문서 (synth_holdout)	25	53	26	39
규칙 + 토큰	일상 문서 (synth_holdout)	**11**	93	19	7

멘토 holdout의 오류(개선 전 미탐 3 · 오탐 65 · 경계 14 · 라벨 3)는 2부 ⑦ Holdout 오류 분석에 따로 정리했다.

3-2. 방식별 대표 사례와 원인

규칙 기반 — 미탐형 약점 (문맥 없는 이름)

유형	사례 (【 】 = 정답)	원인
미탐	메신저 `알겠어. 【현준】이랑 같이 정리해서 올릴게` (test 미탐 12건 중 다수)	성 없이 처음 나오는 이름. 호칭·필드 같은 문맥 단서가 없고 `현준이랑`은 일반 단어와 구분이 안 됨
미탐	`카드운영팀 【정현준】` (인사 발령 목록)	부서명 뒤에 공백 하나로 붙은 이름. 필드·직급 단서 없음
경계	`【은영】이랑 → 은영이`	호격·조사 `이`를 이름의 일부로 퍼뜨림
오탐 (v7까지)	`【고객명】: 이재원 → 고객명을 이름으로`	형태소 분석기가 사전에 없는 단어로 보고 성씨 글자(`고`)로 시작해 이름 후보가 됨. v8의 서식 항목 규칙(⑧)으로 test 오탐 0

유형	사례 (【 】= 정답)	원인
오탐 (일상 문서)	`배송지`, `장인상`(부고), `신청일`, `서울숲`	같은 원인. 장소 접미사·합성어 필터(부록 A-3의 v6)와 v8 서식 항목·부고 규칙으로 대부분 해결. 콜론 없이 문장 안에 쓴 `배송지`(15건)는 아직 남음

형태소 분석기의 한계도 드러났다: Kiwi는 `오세린`을 `오`(숫자 `5`)+`세`(나이)+`린`("다섯 살")으로, `이우리`를 `이`(감탄사)+`우리`로, `백승훈님`을 `백`(숫자 `100`)+`승`+`후`+`ㄴ`으로 분석했다. 그래서 품사만으로 이름을 판단하지 않고, 필드·호칭·말하는 사람 형식 같은 문맥 규칙으로 보완했다. 분석기 5종 비교(Kiwi·Komoran·Kkma·Hannanum·Okt)에서도 **사전에 없는 단어를 표시해 주는 Kiwi**가 이름 재현율 0.985로 가장 높았다(Okt·Hannanum은 0.2 미만).

토큰 분류 (atonlee) — 오탐·경계형 약점

유형	사례	원인
오탐	`내일까지 보고서【달래】`(12건)	구어체 동사 `달래`(달라고 해)를 이름으로 봄
오탐	`하린 포인트 카드`의 `하린`(11건), 회사명 `미르보안`(v7에서 6건)	상품·회사 이름이 사람 이름처럼 생김. `미르보안`은 v8 회사 이름 끝말 후처리로 제거
경계	`정하은` → `정하`, `손하은 책임` → 직함까지, 주소 뒤 조사 `…1301호로`	서브워드 조각 단위 예측이라 이름 끝·조사 경계가 흔들림
미탐	붙여 쓴 지역번호 `0239644249`	학습 데이터에 드문 형식
라벨 오류 (일상 문서)	점 구분 계좌 `003.004900.35793`, 2묶음 계좌를 다른 라벨로	계좌 형식을 좁게 학습 → 일상 문서 계좌 재현율 0.731
정밀도 (일상 문서)	주문·접수번호 등 13자리 숫자를 주민번호로	일상 문서 주민번호 정밀도 0.66(v7) → 0.81(v8, `∞∞` 번호 문맥 후처리)

LLM (gpt-4.1-mini) — 미탐형 약점 (지시 과잉 적용·비결정성)

유형	사례	원인
미탐	메일 서명의 직원 직통번호 `02-3961-1452`	"대표번호·내선번호 제외" 지시를 직통번호까지 넓혀 적용
미탐	`【상훈】아, 오늘 회의 자료…`(이름만 부르기, given 재현율 0.455)	메신저 호칭을 이름으로 보지 않음
미탐	리스크관리팀 `【허수아】`(3회 실행 모두 반복 누락)	같은 이름을 일관되게 놓침
경계	`【서연】아` → `서연아`	호격 조사를 이름에 포함
오탐	내선 `【5647】`을 전화번호로	내선번호 판단 오류

규칙 + 토큰 — 미탐 0, 오탐은 토큰 쪽에서 들어옴

- test 미탐 0: 규칙이 놓친 이름만 쓴 경우를 토큰이 잡고, 토큰이 놓친 붙여 쓴 번호를 규칙이 잡음 (서로 약점이 겹치지 않음)
- 오탐 26건은 모두 토큰의 오탐(`달래` 12, `하린` 11, `이첩` 3)이 그대로 들어온 것 → 정밀도 0.976 (하한선 0.90 위)
- 경계 3건은 규칙의 `은영이` 유형

3-3. 일상 문서에서만 보인 오류

오류	예	판단
계좌 앞 은행 이름 경계	생성 정답 `우리은행 1000-202-340001`, 탐지 `1000-202-340001`	정답 기준 차이 (데이터셋은 번호만). strict에서만 감점
장소 주소	장례식장·파티룸 주소를 생성 정답이 표시	팀 기준상 가리지 않는 게 맞음

오류	예	판단
사업자등록번호·송장번호를 계좌로	`사업자등록번호 123-45-67890`	v6 규칙에서 문맥 단어로 제외
날짜가 맞지 않는 주민번호	`820515-0234521` (뒷자리 0)	`주민번호` 문맥이 있으면 6-7자리를 주민번호로 보도록 v6에서 보완

3-4. 정답 데이터 자체의 문제

- 일상 문서 정답은 생성 모델이 표시해 **표시 누락**이 있다(`예금주: 정세림`, `김미영 부장님`, 집 주소 등 → 탐지기가 맞게 잡아도 오탐으로 채점). 검수 후보 44건을 뽑았고(`results/synth_qc_candidates.csv`), 팀 기준(장소 주소 제외)으로 정답을 다시 맞추면 일상 문서 정밀도와 주소 재현율이 더 정확해진다.
- 제공 데이터에는 `김 과장` 같은 성+직함이 정답에 없다(dev 17, test 40건). 팀 기준과 같아 오탐으로 처리했다.