# 실전 1 보고서 ④ 탐지기 선정 근거

> - **과제**: 금융사 사내 문서에서 개인정보 7종을 찾는 탐지기를 규칙 기반·토큰 분류·LLM 세 방식으로 비교하고, 운영에 쓸 탐지기를 근거 있게 고른다.
> - **데이터**: 제공 `pii_synth_finance` dev 100건(정답 548개) · test 200건(정답 1,165개) / 추가 시험 데이터: 엣지 케이스 64건(정답 116개), 일상 문서 1,983건(정답 3,375개)
> - **채점**: 멘토 제공 `run_compare.py` (strict·partial 정밀도/재현율/F1, mask_rec, 라벨별·어려운 사례 재현율, 일관성)
> - **작성**: 2026-10-23 · 저장소 `hosung` 브랜치 `실전프로젝트1/` · 작업 기록 전체는 `worklog.md`

**보고서 구성**: 0 요약 및 결론 · ① 데이터 관찰 리포트 · ② 방식별 비교표 · ③ 오류 유형 분석 · ④ 탐지기 선정 근거 · ⑤ 개선 과정과 데이터 사용 기록 (`report/` 폴더)

---

## 4-1. 결론

- **운영 탐지기: 규칙 기반 + 토큰 분류(atonlee) 전체 합집합**
- **LLM: 탐지에는 쓰지 않고 RAG 답변 생성에서만 사용 (마스킹된 텍스트만 전달)**

## 4-2. 기준별 판단

| 기준 | 규칙 단독 | 토큰 단독 | **규칙 + 토큰** | LLM 단독 | 규칙 + LLM |
|---|---|---|---|---|---|
| 놓치지 않기: test mask_rec | 0.997 | 0.989 | **1.000** | 0.988 (gpt-4.1-mini) | 1.000 (gpt-5.5) |
| 놓치지 않기: 처음 보는 문서 mask_rec | 0.972 | 0.984 | **0.988** | 미측정 | 미측정 |
| 정밀도 하한선 0.90 (test / holdout) | 0.997 / 0.949 | 0.947 / 0.908 | **0.968 / 0.909** | 0.996 / — | 0.997 / — |
| 속도 (ms/문서, test) | 10 | 102 | **112** | 1,292 | 1,781 |
| 일관성 | 100% | 100% | **100%** | 77.5~98.5% | 88~100% |
| 원문 외부 전송 | 없음 | 없음 | **없음** | 있음 | 있음 |
| CPU 서버 운영 | 가능 | 가능 | **가능** | API 의존 | API 의존 |
| 라이선스 | Kiwi(kiwipiepy) Apache-2.0 | atonlee Apache-2.0 | **둘 다 Apache-2.0** | 상용 API | 상용 API |

## 4-3. 라벨별로 방식을 나눠 쓰는 조합 검토

라벨마다 강한 방식이 다르다: 정형 라벨(전화·계좌·카드)은 규칙이, 이름은 토큰이 강하다(② 방식별 비교표 2-5). 그래서 두 가지 조합을 비교했다.

| 조합 | test mask_rec | holdout mask_rec | holdout strict P |
|---|---|---|---|
| **전체 합집합** (모든 라벨을 합침, 겹치면 규칙 우선) | 1.000 | **0.988** | 0.909 |
| 이름만 결합 (정형 라벨은 규칙만, 이름만 규칙 ∪ 토큰) | 1.000 | 0.976 | 0.940 |

이름만 결합하면 정밀도는 오르지만, 규칙이 놓친 번호·주소를 토큰이 잡아도 버리게 되어 처음 보는 문서에서 mask_rec이 0.012 떨어진다(holdout에서 주민번호 재현율 규칙 0.939 vs 합집합 0.988). 제공 데이터에서는 규칙의 정

형 라벨이 이미 완벽해 두 조합이 같은 점수라 차이가 보이지 않았다. **재현율 우선 기준에 따라 전체 합집합을 선택**했다.

## 4-4. 탈락시킨 방식과 이유

| 방식 | 탈락 이유 (수치) |
|---|---|
| 규칙 단독 | 가장 빠르고 제공 데이터에서 가장 정확하지만, 처음 보는 문서에서 2.8%를 놓침(mask_rec 0.972). dev 문구에 기댄 규칙을 끄면 test 재현율이 약 8%p 떨어짐 → 템플릿이 다른 문서에서 무너질 위험 |
| 토큰 단독 | 엣지 케이스 mask_rec 0.921(안심번호·휴대폰 계좌·외국인등록번호 미탐), 경계가 부정확해 strict F1 0.955, 처음 보는 문서 계좌 재현율 0.731 |
| 다른 토큰 모델 | veil은 mask_rec이 비슷하나 5배 느림, dlp는 22배 느림, seongyeon은 경계 오류가 많고 CC-BY-SA-4.0(사내 배포 시 검토 필요), 기준 모델 bccard는 재현율 0.773 |
| LLM 단독 | 가장 좋은 gpt-5.4-mini도 일관성 81%·미끼 오탐 9. 클로바 HCX-007은 회사 이름을 사람으로 잡고 가장 느리며(2,629ms) 일관성 77.5%, DASH-002는 직원끼리 쓴 문서 32건을 통째로 "개인정보 없음"(mask_rec 0.667). 모두 원문 외부 전송 필요 |
| 규칙 + LLM | test 정확도는 가장 높으나(규칙 + gpt-5.5: mask_rec 1.000, 정밀도 0.997) **재현율 이득이 없음**(규칙 + 토큰도 mask_rec 1.000). 문서당 1,781ms로 **약 16배 느림**(1만 건 약 4.9시간 vs 약 19분), 원문을 외부로 보내야 하고, 문서마다 API 비용 |

## 4-5. 운영 조건 정리

- **원문 외부 전송 없음**: 규칙과 토큰 모델 모두 사내 CPU 서버에서 돌아간다. 개인정보를 찾으려고 원문을 클라우드 LLM에 보내는 모순이 없다.
- **CPU 환경**: GPU 없이 문서당 약 0.1초. 1만 건 약 19분(보수적 측정), 부하가 적을 때 약 9분.
- **라이선스**: Kiwi(kiwipiepy) Apache-2.0, atonlee Apache-2.0. 학습 데이터(`BCCard/pii-masking-openpii-finance`, `townboy/korean-pii-dataset`)는 CC BY 4.0이며 모델 저장소가 재배포하지 않는다.
- **일관성 100%**: 같은 문서는 언제나 같은 결과 → 실전 2에서 같은 사람이 같은 가명 토큰을 받는다.
- **LLM은 RAG에서만**: 답변 생성에는 마스킹된 텍스트만 보낸다. 종합 단계의 출력 재검사에 LLM을 쓸지는 사내 LLM 여부에 따라 다시 검토한다.