실전 1 보고서 2부 ⑤ Holdout 데이터 관찰

> - **과제**: 금융사 사내 문서에서 개인정보 7종을 찾는 탐지기를 규칙 기반·토큰 분류·LLM 세 방식으로 비교하고, 운영에 쓸 탐지기를 근거 있게 고른다.
> - **데이터**: 제공 `pii_synth_finance` dev 100건(정답 548개) · test 200건(정답 1,165개) / 추가 시험 데이터: 엣지 케이스 64건(정답 116개), 일상 문서 1,983건(정답 3,375개) / **멘토 holdout 187건(정답 912개)**
> - **채점**: 멘토 제공 `run_compare.py` (strict·partial 정밀도/재현율/F1, mask_rec, 라벨별·어려운 사례 재현율, 일관성)
> - **작성**: 2026-10-26 · 저장소 `hosung` 브랜치 `실전프로젝트1/` · 작업 기록 전체는 `worklog.md` (21~24장)

보고서 구성: 0 요약 및 결론 · **1부** ① 데이터 관찰 리포트 · ② 방식별 비교표 · ③ 오류 유형 분석 · ④ 탐지기 선정 근거 · **2부** ⑤ Holdout 데이터 관찰 · ⑥ Holdout 성능 · ⑦ Holdout 오류 분석 · ⑧ Holdout 개선 내역 · 부록 개선 과정과 데이터 사용 기록 (`report/` 폴더)

> **2부 진행 순서**: holdout 받음 → 탐지기를 고치지 않고 **먼저 채점·기록**(⑥ 개선 전) → 데이터 관찰(⑤) → 오류 분석(⑦) → 개선과 재채점, dev·test 재확인(⑧). 개선 후 holdout 점수는 holdout 오류를 보고 맞춘 값이라 **일반화 성능이 아니다.**

멘토 배포 파일 `holdout/holdout_labeled.jsonl` 을 dev·test와 같은 방법으로 라벨별로 모아 (`data/gold_by_label_holdout/<라벨>.csv`) 비교했다. holdout에는 `template`, `person_id`, `roles` 필드가 없어 템플릿 비교·같은 사람 묶기는 하지 않았다.

5-1. 전체 구성

항목	dev + test	holdout
문서 수 / 정답 수	300 / 1,713	187 / 912
문서당 개인정보	5.7개	4.9개
문서 평균 길이	279자	206자
개인정보 없는 문서	50 (17%)	14 (7%)
문서 유형	14종	**20종, 그중 19종이 처음 보는 유형** (겹치는 것은 `공지` 뿐)

holdout 문서 유형: 녹취요약, 출장보고, 한도심사결과, 분쟁조정, 감사지적, VOC요약, 법인카드소명, 경조사공지, 카드발급심사, 가맹점변경, 고객편지, 채용메일, 권한신청, 피해접수, 영문혼용메일, 대리인위임확인, 자동이체신청서, 우편반송처리, 해외송금접수, 공지

5-2. 라벨별 개수

라벨	dev + test	holdout
person	1,115 (65%)	560 (61%)
phone_number	250 (15%)	147 (16%)
email	113 (7%)	43 (5%)
address	104 (6%)	52 (6%)
주민등록번호	47 (3%)	43 (5%)
account_number	43 (3%)	41 (4%)
card_number	41 (2%)	26 (3%)

이름 비중이 조금 줄고 번호류(주민·계좌·카드) 비중이 늘었다.

5-3. 표기 형태 — 가장 크게 달라진 부분

라벨	dev + test	holdout
주민등록번호	`999999-9999999` **한 가지**	붙여쓰기 17 · **공백** 13 · 하이픈 13
계좌번호	`999-999999-99` **한 가지**	**8가지 이상**: 3-6-2(9), 4-3-6(9), 4-2-7(5), 3-2-6-1(5), 3-3-6(3), 붙여쓰기(3), 6-2-6(2), 2-6-6(2) …
카드번호	`9999-9999-9999-9999` **한 가지**	붙여쓰기 10 · 하이픈 9 · **공백** 7
전화번호	010 위주, 02 지역번호 17	02 지역번호 **35**, **국제번호** `+82 10-…` **25개 (새로 등장)**, 점·공백·붙여쓰기
주소	도로명 + 시도 정식 이름	**지번(동·리) 31 > 도로명 21**, 시도 줄임말(`서울` , `부산` , `대구`), 아파트 이름 + 동·호수, 앞에 우편번호 `(05299)`
이메일	이니셜.성+숫자@도메인	비슷함

이름

항목	dev + test	holdout
외자 (성 + 이름 1글자, `안윤` , `박별` , `오담`)	59 (5%)	**73 (13%)**
4글자 (복성 `남궁나연` , `황보현우` , `제갈라온` , `선우이안`)	16 (1%)	**32 (6%)**
한 글자 이름 (`린 님`)	0	1
띄어 쓴 이름 / 이름만	78 / 59	53 / 36
이름 뒤 조사·말	`님` 50, `은` 34, `입니다` 27, `이` 23, `아` 13	`님` 37, `이` 36, **`에(게)` 28**, **`인데요` 11**, **`의` 10** (새 결합)

5-4. 어려운 사례 태그 (문서 수)

태그	dev + test	holdout
phone_format_variant	65	75
spaced_name	78	53
josa_attached	74	37
given_only	44	36
homonym	72	29
surname_title_unlabeled (`김 과장`)	57	26
decoy_company_phone / decoy_words / decoy_numbers	37 / 30 / 10	8 / 14 / 6
no_pii	50	14
address_format_variant (새)	—	33
id_format_variant (새)	—	30
single_char_given_name (새)	—	29
card_format_variant (새)	—	25
account_format_variant (새)	—	23
compound_surname (새)	—	15

5-5. 해석

- holdout은 **처음 보는 문서 유형 19종 + 다양한 표기**로, dev·test의 "같은 템플릿·형식 한 가지" 한계를 정확히 겨냥한 데이터다.
- 새로 생긴 형식 대부분은 **팀이 엣지 케이스·일상 문서로 미리 대비했던 것**이다: 국제번호 `+82`, 은행별 계좌 자릿수, 붙여쓰기·공백 카드·주민번호, 지번·시도 줄임말 주소, 외자·복성 이름, 건물명 + 동·호수. 개선 전 점수가 유지된 이유로 본다(⑥, mask_rec 0.993).
- 미리 대비하지 못한 것: 이름 뒤 새 결합(`에게`, `인데요`, `의`), 한 글자 이름, 주소 앞 우편번호, 계좌 3-2-6-1 같은 마지막 1자리 형식, 새 문서 유형의 서식 항목(`소명자:`, `위임인:`) → ⑦ 오류 분석에서 확인했다.