실전 1 보고서 ⑤ 개선 과정과 데이터 사용 기록

> - **과제**: 금융사 사내 문서에서 개인정보 7종을 찾는 탐지기를 규칙 기반·토큰 분류·LLM 세 방식으로 비교하고, 운영에 쓸 탐지기를 근거 있게 고른다.
> - **데이터**: 제공 `pii_synth_finance` dev 100건(정답 548개) · test 200건(정답 1,165개) / 추가 시험 데이터: 엣지 케이스 64건(정답 116개), 일상 문서 1,983건(정답 3,375개)
> - **채점**: 멘토 제공 `run_compare.py` (strict·partial 정밀도/재현율/F1, mask_rec, 라벨별·어려운 사례 재현율, 일관성)
> - **작성**: 2026-10-23 · 저장소 `hosung` 브랜치 `실전프로젝트1/` · 작업 기록 전체는 `worklog.md`

보고서 구성: 0 요약 및 결론 · ① 데이터 관찰 리포트 · ② 방식별 비교표 · ③ 오류 유형 분석 · ④ 탐지기 선정 근거 · ⑤ 개선 과정과 데이터 사용 기록 (`report/` 폴더)

5-1. 원칙

- **개선은 dev로만** 하고, test는 중간 확인에만 쓴다(멘토 안내).
- holdout을 받지 못해, 일상 문서 1,983건을 반으로 나눠 **개선용(synth_dev 989건)**과 **오류를 끝까지 보지 않는 holdout(synth_holdout 994건)**으로 썼다.

5-2. 실제 사용 기록 (그대로 밝힘)

시점	test 사용	비고
v1 (첫 비교)	점수와 **오류 목록을 봄**	첫 비교 결과 확인
v2 (모델 후처리, 규칙 일반화)	점수 확인	**v2 아이디어 일부(대표번호·민원번호 거르기, `신승현 과장` 유형)가 v1 test 오류를 보고 나왔다.** 구현은 dev로 했지만 같은 템플릿이라 test 정보가 간접적으로 들어갔다 → 제공 test 점수는 낙관적일 수 있음
v3~v7	**점수만 확인, 오류 목록은 보지 않음**	멘토 안내 이후 원칙을 지킴
일상 문서 holdout	처음부터 끝까지 점수만 확인	규칙 v5 → v6에서 오류를 보지 않았는데도 mask_rec 0.966 → 0.980 개선 = 일반화 근거

그래서 **처음 보는 문서 성능은 synth_holdout 점수(규칙 + 토큰 mask_rec 0.988)를 대표값으로** 본다.

5-3. 규칙 기반 버전별 변화

버전	주요 변경 (개선에 쓴 데이터)	test strict F1	holdout mask_rec
v1	정규식 + Kiwi 이름 규칙, 날짜를 계좌에서 제외, 사전 일반명사 필터 (dev)	0.954	—
v2	이름 규칙 일반화(3글자 + 직급, `님` 분리, 접미사 필터) (dev)	0.983	—
v3	지역번호·은행별 계좌·지번 주소·외국인 이름 등 엣지 형식 (엣지 케이스)	0.986	—
v4	문서 안 이름 퍼뜨리기, 서명, 은행명 (엣지 케이스)	0.991	—
v5	참석자 목록, 메신저 말하는 사람 (엣지 케이스)	0.993	0.966
v6	사업자·송장번호 제외, 주민번호 문맥, 건물명, 장소·합성어 오탐 필터 (synth_dev)	0.993	0.980
v7	장소 주소 제외 (팀 기준)	0.993	0.972*

* v7의 holdout 하락은 생성 정답이 장소 주소를 표시했기 때문(팀 기준과 정답 기준 차이). 주소 정밀도는 0.90 → 0.98로 올랐다.