실전 1 보고서 부록 — 개선 과정과 데이터 사용 기록

> - **과제**: 금융사 사내 문서에서 개인정보 7종을 찾는 탐지기를 규칙 기반·토큰 분류·LLM 세 방식으로 비교하고, 운영에 쓸 탐지기를 근거 있게 고른다.
> - **데이터**: 제공 `pii_synth_finance` dev 100건(정답 548개) · test 200건(정답 1,165개) / 추가 시험 데이터: 엣지 케이스 64건(정답 116개), 일상 문서 1,983건(정답 3,375개) / **멘토 holdout 187건(정답 912개)**
> - **채점**: 멘토 제공 `run_compare.py` (strict·partial 정밀도/재현율/F1, mask_rec, 라벨별·어려운 사례 재현율, 일관성)
> - **작성**: 2026-10-23, 수치 갱신 2026-10-26 (탐지기 v8) · 저장소 `hosung` 브랜치 `실전프로젝트1/` · 작업 기록 전체는 `worklog.md`

보고서 구성: 0 요약 및 결론 · **1부** ① 데이터 관찰 리포트 · ② 방식별 비교표 · ③ 오류 유형 분석 · ④ 탐지기 선정 근거 · **2부** ⑤ Holdout 데이터 관찰 · ⑥ Holdout 성능 · ⑦ Holdout 오류 분석 · ⑧ Holdout 개선 내역 · 부록 개선 과정과 데이터 사용 기록 (`report/` 폴더)

A-1. 원칙

- **개선은 dev로만** 하고, test는 중간 확인에만 쓴다(멘토 안내).
- 멘토 holdout을 받기 전에는, 일상 문서 1,983건을 반으로 나눠 **개선용(synth_dev 989건)**과 **오류를 끝까지 보지 않는 holdout(synth_holdout 994건)**으로 썼다.

A-2. 실제 사용 기록 (그대로 밝힘)

시점	test 사용	비고
v1 (첫 비교)	점수와 **오류 목록을 봄**	첫 비교 결과 확인
v2 (모델 후처리, 규칙 일반화)	점수 확인	**v2 아이디어 일부(대표번호·민원번호 거르기, `신승현 과장` 유형)가 v1 test 오류를 보고 나왔다.** 구현은 dev로 했지만 같은 템플릿이라 test 정보가 간접적으로 들어갔다 → 제공 test 점수는 낙관적일 수 있음
v3~v7	**점수만 확인, 오류 목록은 보지 않음**	멘토 안내 이후 원칙을 지킴
일상 문서 holdout	처음부터 끝까지 점수만 확인	규칙 v5 → v6에서 오류를 보지 않았는데도 mask_rec 0.966 → 0.980 개선 = 일반화 근거
멘토 holdout (v7 → v8)	**수정 없이 먼저 채점·기록** → 오류 분석 → v8 개선 → 재채점	개선 후 holdout 점수는 오류를 보고 맞춘 값이라 일반화 성능이 아님(⑧). v8 후 dev·test·엣지·일상 문서 재확인

그래서 **처음 보는 문서 성능은 synth_holdout 점수(규칙 + 토큰 mask_rec 0.988)를 대표값으로** 본다.

A-3. 규칙 기반 버전별 변화

버전	주요 변경 (개선에 쓴 데이터)	test strict F1	holdout mask_rec
v1	정규식 + Kiwi 이름 규칙, 날짜를 계좌에서 제외, 사전 일반명사 필터 (dev)	0.954	—
v2	이름 규칙 일반화(3글자 + 직급, `님` 분리, 접미사 필터) (dev)	0.983	—
v3	지역번호·은행별 계좌·지번 주소·외국인 이름 등 엣지 형식 (엣지 케이스)	0.986	—

버전	주요 변경 (개선에 쓴 데이터)	test strict F1	holdout mask_rec
v4	문서 안 이름 퍼뜨리기, 서명, 은행명 (엣지 케이스)	0.991	—
v5	참석자 목록, 메신저 말하는 사람 (엣지 케이스)	0.993	0.966
v6	사업자·송장번호 제외, 주민번호 문맥, 건물명, 장소·합성어 오탐 필터 (synth_dev)	0.993	0.980
v7	장소 주소 제외 (팀 기준)	0.993	0.972*
v8	서식 항목(소명자: 등) 오탐 제거, 직함·부고 단어, 띄어 쓴 외자, 필드 추가, 계좌 마지막 1자리, 읍 + 번지, 우편번호 (멘토 holdout 오류 분석, ⑦·⑧)	0.993	0.972
v9	이름 뒤 조사·호칭 떼기(규칙·토큰 공통), 부서에 붙은 이름·번호 뒤 괄호 이름, 050- · 82-10- 전화, 점 구분 카드, 공백 구분 계좌, at 이메일, 붙인 우편번호·건물 + 동·호수 주소, 합칠 때 주소는 긴 쪽 (어려운 표기 개선용 반, A-4)	0.993	0.977
v10	이 로 끝나는 이름(백송이)과 이름 + 주격 조사 이 (안윤이) 구분: 같은 문서 안 다른 표기(백송이님 · 안윤 대리)와 바로 뒤 직함·호칭으로 판단 (사용자 질문에서 발견, 규칙·토큰 공통)	0.993	0.977

* v7의 holdout 하락은 생성 정답이 장소 주소를 표시했기 때문(팀 기준과 정답 기준 차이). 주소 정밀도는 0.90 → 0.98로 올랐다. 표의 holdout은 일상 문서 평가용(synth_holdout)이다.

A-4. 2차 평가 세트와 v9 개선

dev·test·엣지·일상 문서·멘토 holdout을 모두 한 번 이상 보고 고쳐서, 처음 보는 문서 성능을 깨끗하게 잴 세트가 없어졌다. 그래서 OpenAI gpt-4.1로 두 세트를 새로 만들었다(worklog 26~28장).

세트	문서 / 정답	내용	용도
synth_fresh	1,775 / 5,918	dev·test·holdout에 없던 금융 업무 문서 25종, 문서마다 표기 계획을 무작위로 지정	**평가 전용** (고치는 데 안 씀)
synth_hard_dev	379 / 1,892	일부러 어렵게 만든 표기: 외자·일반 단어 같은 이름·메신저 호격·부서에 붙은 이름· at 이메일·붙여 쓴 지역번호 등	**개선용** (오류를 봄)
synth_hard_eval	403 / 1,958	같은 방식, 나머지 반	**평가용** (점수만)

정답 품질 관리: 생성 모델이 어려운 값의 표시를 절반 가까이 빠뜨려서(hard 표시 2,716 → 보정 후 4,675) 다른 호출로 **표시를 보정**하고, 팀 기준을 넣은 검수에서 문제가 나온 문서는 **고치지 않고 뺐다**(fresh 9%, hard 17%). 우리 탐지기는 정답 만들기에 쓰지 않았다.

v8 그대로 첫 채점 → v9 (규칙 + 토큰)

데이터	역할	strict P	strict F1	mask_rec
synth_hard_dev	개선용	0.790 → 0.868	0.799 → 0.875	0.951 → 0.978
synth_hard_eval	평가용	0.787 → **0.871**	0.781 → **0.861**	0.933 → **0.964**
synth_fresh	평가 전용	0.855 → **0.920**	0.855 → **0.920**	0.976 → **0.983**
일상 문서 평가용		0.934 → 0.939	0.956 → 0.961	0.988 → 0.989
dev · test · 엣지 · 멘토 holdout		그대로	그대로	그대로

- 개선용 반에서 찾은 가장 큰 원인: 규칙이 서식 칸 예약자: 최민재님 을 조사째 이름으로 잡아 문서 전체로 퍼뜨리고, 합칠 때 규칙이 우선이라 토큰이 맞힌 최민재 를 덮어씀. 합집합이 토큰 단독보다 나빠진 69건이 모두 이런 규칙 쪽 잘못이었다

- 남은 한계: **이름 재현율은 거의 그대로**(평가용 반 0.836 → 0.843). `하늘`·`가람` 같은 일반 단어 이름, 호격, 성 없는 이름은 문맥 없이 일반 단어와 구분하기 어렵다. 평가용 반 정밀도 0.871은 하한선 0.90 아래(어려운 표기만 모은 세트)
- v10(`이`로 끝나는 이름 처리) 뒤: 평가용 반 strict F1 0.861 → 0.866, fresh 0.920 → 0.923, 다른 세트는 그대로. 9개 세트에서 떨어진 지표 없음
- 주의: fresh와 hard는 같은 생성 프롬프트 계열이라, fresh 개선 폭에는 같은 생성기 표기 습관에 맞춘 효과가 섞여 있을 수 있다